

2018 下學期機器學習 Final Project

組員 : 0616018 林哲宇 0616084 林柏均
0516017 李柏毅 0313340 邱韋
0413233 李彥儒


一、題目與動機

題目:文章檢測器

動機:

1. ptt 版主目前的工作
2. 本身的 ptt 使用經驗

二、取得資料



ppt首頁

The screenshot shows a list of boards from the PTT homepage. Each board entry includes its name, ID, category, and a brief description.

版名	ID	類別	說明
Gossiping	13709	綜合	◎【八卦】願天下有情人終成眷屬
NBA	3953	籃球	◎[NBA] 6/03 8:00 NBA總冠軍戰 G2
Baseball	3526	棒球	◎[棒球]中職三十 Baseball is Life
C_Chat	3211	閒談	◎[希洽] 震憾彈! 姆咪即將走入歷史!
Stock	2613	學術	◎本板新增板主投票已開始
HatePolitics	1692	Hate	◎[政黑] 用念力為高雄祝福！
movie	1556	綜合	◎沒看電影不會知道就是標題雷
LoL	1292	遊戲	◎[LoL]
MobileComm	1285	資訊	◎問機文用範本 發文前請看板規
Lifeismoney	1125	省錢	◎[省錢] 2020板主大選
sex	1094	男女	◎[西斯] 徵文票選中 !! (二號投票)
Tech_Job	1062	工作	◎[科技] 凡事切記 獨立思考
Elephants	1049	CPBL	◎6/1~6/2 GATE★B835 in洲際
Tennis	927	網球	◎[網球] 法網2019
car	899	車車	◎[汽車] 發文前請閱讀板規
WomenTalk	889	聊天	◎[女孩] 板主投票留言者抽 500P
KoreaStar	841	韓國	◎[韓星] 發/推文前請務必詳閱板規
BabyMother	817	家庭	◎[媽寶] 母親節快樂!!
Boy-Girl	806	心情	◎[男女] 置底請詳閱
KR_Entertain	783	綜藝	◎[韓綜] Show Me The 新板主!
Beauty	768	聊天	◎《表特板》發文附圖
PC_Shopping	694	種類	◎「雷船」全國最大客服？小心升級BUG

ptt 分類 index

The screenshot shows the homepage of the PTT Gossiping board (Gossiping). At the top, there is a navigation bar with links to various categories like youtube, Tom, anime, CTF, bigData, nctu, and pcca. Below the navigation bar, the title "批踢踢實業坊 > 看板 Gossiping" is displayed. On the right side of the header, there are links for "聯絡資訊" and "關於我們". The main content area features a search bar labeled "搜尋文章…". Below the search bar is a list of 10 posts, each with a number, subject, author, date, and a more button (...). The posts are:

- 4 [問卦] 暫停申請新帳號=沒新人加入，是不去假議
vios1009 5/31 ...
- 7 [問卦] 白石 茉莉奈這天是我最後能為妳做的事....
alan4ni 5/31 ...
- 1 [問卦] 老闆把我的雞排切了老板切了我的雞排
hongou 5/31 ...
- [新聞] 蘇丹示威抗議不斷 軍方關閉半島電視台
JyumonjiKaho 5/31 ...
- [問卦] 西門町沒落時是什麼樣子
w854105 5/31 ...
- 3 [新聞] 一條毛巾在太空飄了10年 終於被太空人收回
maruEX 5/31 ...
- [問卦] 手機吃到飽是台灣特有的產物嗎?
safelyfuck 5/31 ...
- [問卦] 爹孫戀還在嗎
OGC100times 5/31 ...
- [問卦] 這樣算抓到女同學是鄉民嗎?
中 5/31 ...

At the bottom of the page, there is a toolbar with icons for different functions and a footer with navigation links.

文章內頁

https://www.ptt.cc/bbs/Gossiping/M.1559310505.A.884.html

youtube Tom anime CTF bigData nctu pcca

批踢踢實業坊 > 看板 Gossiping

聯絡資訊 關於我們

作者 vios10009 (湖裡塗糊)

標題 [問卦] 暫停申請新帳號=沒新人加入，是不是假議題？

時間 Fri May 31 21:48:23 2019

看板 Gossiping

餓死抬頭
那個拉，PTT從去年9/15日暫停帳號申請至今已經快九個月了。
爬文章時經常看到有鄉民們嘆氣說八卦都沒新人加入，是不是官方該開放帳號註冊的言論。
可是本肥覺得，這兩個事情好像對不上邊？
本版的要求是360天登入才能發廢文，所以就算沒有停止註冊，後來加入的也還不能發文，而在這之前創的則仍然會入續續的進來。
新血停止的時間應該是再過三個月，怎麼會現在就把停止註冊跟沒新血進來劃上等號呢？
有沒有暫停申請新帳號=沒新人加入是假議題的卦？

--

* 發信站: 批踢踢實業坊(ptt.cc), 來自: 124.11.211.232
* 文章網址: <https://www.ptt.cc/bbs/Gossiping/M.1559310505.A.884.html>
* 編輯: vios10009 (124.11.211.232), 05/31/2019 21:48:52


推 i1w4e: 應該是很多小朋友會想註冊來玩啦，但在廠工洗文下不知道是 05/31 21:49
→ kabuasua: ptt還有其他版啊 05/31 21:49
→ 11w4e: 知道啦，不過還是要尊重各個版規 05/31 21:49

輸出格式


id	Category	words
1	Gossiping	"明星","外遇","柏均"
2	NBA	"投出","五個","三分球"
3	tech_job	"監督","公司","出貨"

id	Category	words
1	Gossiping	"明","星","外","遇","柏","均"
2	NBA	"投","出","五","個","三","分","球"
3	tech_job	"監","督","公","司","出","貨"

三、資料前處理



資料視覺化



128 categories same ratio articles

四、訓練模型

i.Bayes

ii.Decision Tree

iii.Random Forest

iv.NN

v.Linear Regression



預測結果

Accuracy

Bayes gaussian:0.44

Desicion Tree : 0.63

Random Forest : 0.55

NN : 0.799

Linear Regression :0.43



五、遇到難題

1. 抓取完整的資料遇到的各種狀況

solved

2. 透過 jieba 所得到字詞分類會讓整個 array 變得太大

solved.....but too late

3. 希望能處理各國字詞與圖片


cannot be done before deadline

解決方法


Gossiping	NBA	tech_job
"明星","外遇","柏均"	"投出","五個","三分球"	"監督","公司","出貨"

"明星","在","公司","投出","三分球"				
id	category	Gossiping	NBA	tech_job
1	gossiping	1	2	1

nn overfitting



```
37091/37091 [=====] - 15s 410us/step  
acc: 0.6069936103113857
```



```
37091/37091 [=====] - 13s 351us/step  
acc: 0.7996549028082177
```

謝謝大家

